

PGM 848 - Avanços Científicos em Genética e Melhoramento de Plantas I
VISÃO COMPUTACIONAL NO MELHORAMENTO DE PLANTAS



LISTA 3 - RE0 3

Discentes:

Everton da Silva Cardoso

Lorena Caroline Dumbá Silva

Júlio Augusto de Castro Miguel

Reberth Renato da Silva

Prof.: Vinícius Quintão Carneiro

LAVRAS-MG

2020

SUMÁRIO

1.QUESTÕES.....	3
2. REFERÊNCIAS.....	14

1.QUESTÕES:


Selecione uma imagem a ser utilizada no trabalho prático e realize os seguintes processos utilizando as bibliotecas OPENCV e Scikit-Image do Python:

a) Aplique o filtro de média com cinco diferentes tamanhos de kernel e compare os resultados com a imagem original;

Essa imagem foi obtida por meio de um processo de amostragem dos grãos das parcelas da cultivar Carioca MG que já foi lançada a alguns anos no mercado. Para obtenção das imagens foi utilizado o equipamento Ground Eye. Nesse caso, utilizamos a técnica da suavização que consiste na retirada de foco da imagem. Ela está embasada na alteração dos valores dos pixels da imagem. Esse processo é denominado de convolução. Os Kernels consideram os vizinhos e alteram esses valores. Assim, determinamos quantos pixels vizinhos serão alterados utilizando diferentes escalas Kernels. O princípio básico considera a média dos pixels vizinhos mais próximos. Desse modo, é possível alterar os valores dos pixels dessa região. Sempre o tamanho do Kernel deve ser considerado como um número ímpar. A função específica que realiza o filtro de média está no pacote OPENCV e é denominada de `cv2.blur`.

Na Fig. 1 foi possível observar que quanto maior o Kernel, ou seja, quanto maior o número de pixels vizinhos considerados, mais a imagem perde em termos de foco, nitidez. Desse modo, podemos afirmar que quanto maior o número de vizinhos, aumenta-se a perda do foco da imagem. Quanto maior o tamanho do Kernel, mais desfoca a imagem o que dificulta o processo de identificação dos objetos. Assim, é necessário identificar um tamanho adequado de Kernel para o processamento das imagens de interesse. Esse procedimento deve ser feito empiricamente, torna-se necessário adequar um tamanho para cada imagem de interesse e isso é dependente de diversos elementos que compõe a imagem. Nesse exemplo um dos tamanhos adequados de Kernel foi o de 5x5 ou o de 11x11, uma vez que eles garantiram a qualidade da imagem e minimizam os ruídos da imagem. Esse fato pode ser verificado com a própria análise da imagem com a aplicação do Zoom em cada uma das imagens que compõem a fig.1. Os outros tamanhos de Kernel não foram adequados para o processamento de grãos de feijão, uma vez que a imagem perdeu em termos de nitidez, perdendo-se o foco da imagem.

Fig 1: Diferentes tipos de filtro de média com tamanhos alterados de Kernel.



Fonte: Dumbá (2020)

b) Aplique diferentes tipos de filtros com pelo menos dois tamanhos de kernel e compare os resultados entre si e com a imagem original.

Como foi possível observar no exemplo anterior o filtro de média é possível de ser feito alterando-se o tamanho do Kernel para poder alterar a intensidade dos ruídos da imagem. Contudo, essas modificações podem influenciar diretamente na nitidez da imagem e, por isso, é necessário testes para que seja identificado um nível adequado para o processamento da imagem. Além desse filtro existem outros tipos que podem trazer algumas vantagens dependendo do tipo de imagem e para identificarmos o mais adequado é necessário que sejam realizados testes.

Os outros tipos de filtro que existem são o Filtro Gaussiano que faz a média ponderada, porém os vizinhos mais próximos possuem peso maior. O Filtro de Mediana que calcula a mediana dos valores que estão na vizinhança, normalmente ele gera imagens mais agradáveis. O Filtro bilateral possui o detalhe para identificar melhor as bordas e determina a média ponderada. Elimina os valores de pixels mais distantes. Nesse caso devemos informar o quanto vai eliminar de outlier dessa função.

Nesse exemplo, o filtro que permitiu uma imagem mais agradável foi o filtro de mediana com Kernel de 31x31. Ele garantiu minimizar os ruídos da imagem. Contudo, outros tamanhos de kernel podem garantir uma melhoria em termos de nitidez para essa imagem, como no exemplo anterior para o tamanho de Kernel de 5x5 e 11x11. Desse modo, como o tamanho de Kernel utilizado foi maior do que o nível adequado os diferentes tipos de filtro utilizados não garantiram uma boa qualidade para o processamento e retirados dos ruídos da imagem. A maior parte deles geraram uma perda da nitidez que foi devido ao tamanho do Kernel.

Fig 2: Diferentes tipos de filtros com dois tamanhos de Kernels.

Fonte: Dumbá (2020)

c) Realize a segmentação da imagem utilizando o processo de limiarização. Utilizando o reconhecimento de contornos, identifique e salve os objetos de interesse. Além disso, acesse as bibliotecas Opencv e Scikit-Image, verifique as variáveis que podem ser mensuradas e extraia as informações pertinentes (crie e salve uma tabela com estes dados). Apresente todas as imagens obtidas ao longo deste processo.

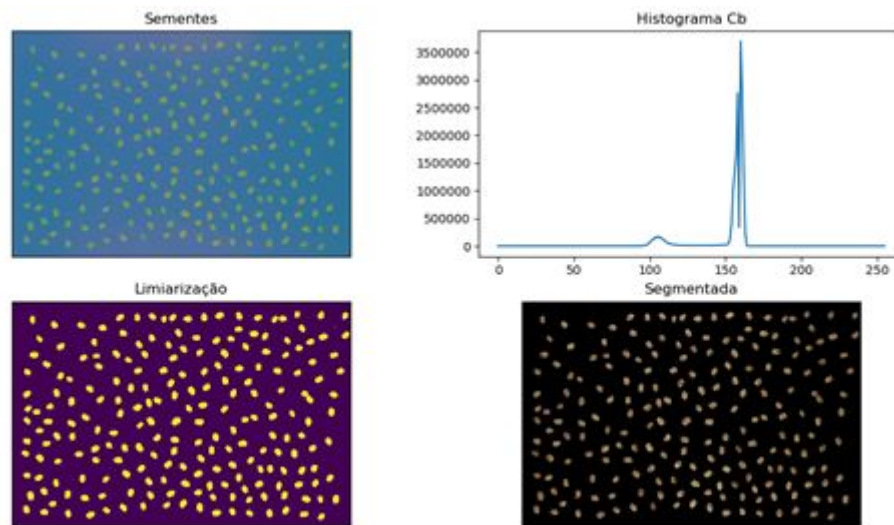
Algumas técnicas de limiarização podem ser utilizadas para agrupar regiões com pixels específicos na imagem. A técnica de Otsu é automática e permite melhor eficiência do processo de separação. Desse modo, as técnicas de segmentação mais utilizadas visam agrupar os pixels mais similares em determinadas regiões da imagem. A primeira etapa do processo consiste em gerar uma imagem binária em que ao conjunto de pixels cuja intensidade é superior ao limiar estabelecido previamente é atribuído o valor 1 (branco) e os pixels com intensidade inferior a esse limiar é atribuído valor zero (preto).

Para escolher o limiar podemos utilizar o método proposto por Otsu (1979) visa definir de forma automática o limiar. Esse método consiste em identificar o valor de limiar que minimiza a variância dentro da classe dos pixels brancos e pretos após a aplicação dessa técnica. Imagens com problemas em sua aquisição e presença de ruídos dificultam a identificação desse limiar, uma vez que no histograma os picos podem não estar bem definidos, por isso é adequado utilizar os filtros.

O sistema YCrCb foi um sistema adequado para realizar o processo de segmentação da imagem. O limiar a separação no canal Cb permite limpar o fundo dos ruídos e os preenche. A filtragem altera o valor dos pixels, altera o histograma e a limiarização e melhora o processo de segmentação da imagem. Desse modo, o novo processo de segmentação se torna mais eficiente do que os processos anteriores em que não havia um tratamento prévio da imagem. Por meio do histograma do canal Cb podemos identificar dois picos, um relativo ao fundo e o outro relativo aos grãos.


Essa técnica de segmentação permite identificar cada elemento da imagem que nesse exemplo são os grãos de feijão e com isso é possível realizar todas as mensurações necessárias.

Fig 3: Imagem no sistema YCrCb, histograma do canal Cb, limiarização e segmentação de OTSU.



Fonte: Dumbá (2020)

Fig 4: Segmentação e técnica de reconhecimento do contorno de uma semente de feijão.



Fonte: Dumbá (2020)

Tabela 1: Tabela com as medidas físicas e de cor dos grãos de feijão.

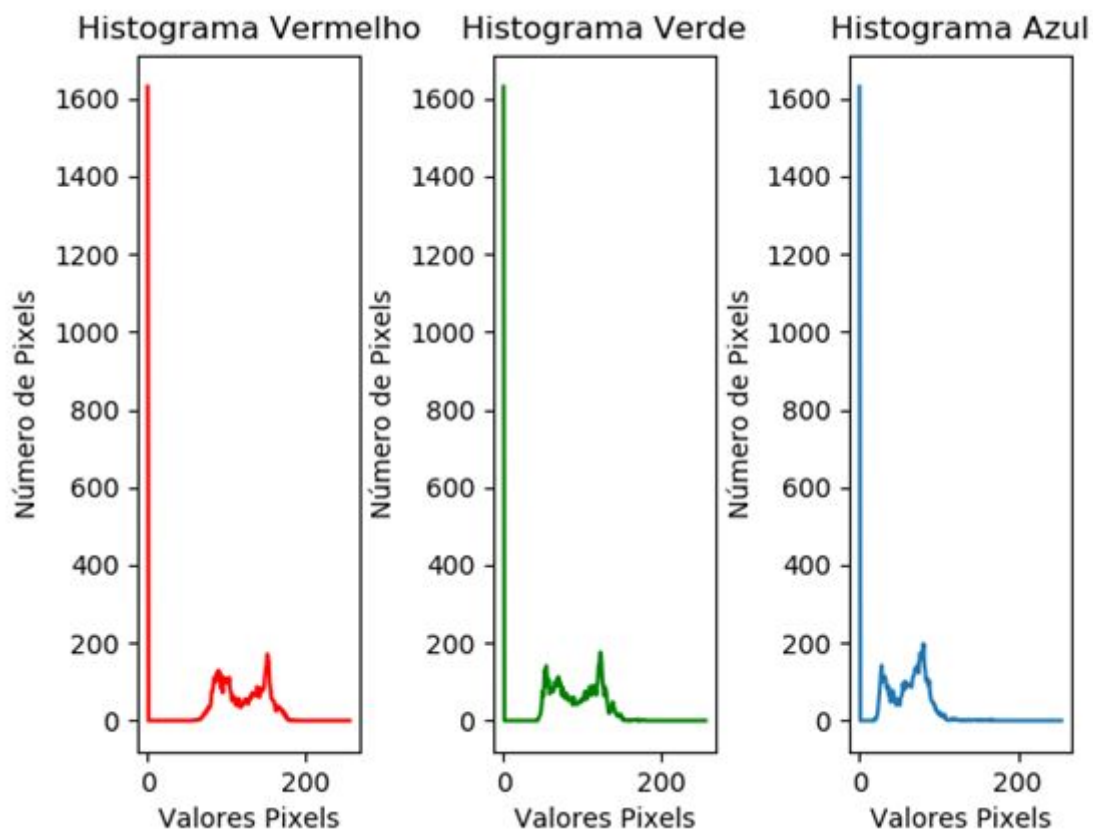
Medidas Físicas	
Centroide	(51.63848108413326, 41.577357425183514)
Comprimento do eixo menor	82.04262526
Comprimento do eixo maior	110.3256807
Razão	1.34473611
Área	6942.5
Perímetro	318.6934325
Medidas de Cor	
Valor Mínimo no R	58.0 - Posição (49, 102)
Valor Máximo no R	188.0 - Posição (7, 39)
Média no Vermelho	(120.14144551101072, 0.0, 0.0, 0.0)
Valor Mínimo no G	42.0 - Posição (15, 20)
Valor Máximo no G	179.0 - Posição (7, 39)
Média no Verde	(92.80872388481083, 0.0, 0.0, 0.0)
Valor Mínimo no B	16.0 - Posição (50, 66)
Valor Máximo no B	171.0 - Posição (7, 38)
Média no Azul	(63.43365330321851, 0.0, 0.0, 0.0)

Na tabela 1 estão listadas as medidas mais relevantes para a análise da imagem dos grãos. Foram obtidas essas mesmas medidas para cada um dos grãos da imagem e isso permite fazer uma análise sobre os aspectos como tamanho e coloração além de ser uma técnica interessante para mensurar o número de grãos total da amostra que no caso dessa imagem foram de 221.

d) Utilizando máscaras, apresente o histograma somente dos objetos de interesse.

Observando os histogramas gerados em sistema RGB, onde está aplicado a máscara para segmentação, é possível observar um pico principal, o qual remete a coloração dos grãos, e um lateral identificado com menor intensidade no CANAL B e com menor intensidade no canal R, ocasionado pela raja do feijão carioca, fato que se observa a dificuldade da separação da listra para avaliar de coloração dos grãos, devido a proximidade dos valores de pixel.

Fig 5: Histograma dos diferentes canais RGB de uma semente de feijão.




Fonte: Dumbá (2020)

e) Realize a segmentação da imagem utilizando a técnica de k-means. Apresente as imagens obtidas neste processo.

Essa técnica de segmentação consiste em aprendizado de máquina. Utilizamos ela quando não conseguimos segmentar com outras técnicas. Ela é utilizada quando tem muitas regiões, objetos na imagem. É uma técnica de agrupamento, ela agrupa os pixels que possuem colorações semelhantes. No caso devemos definir anteriormente os grupos pelos quais queremos separar. Vai ter uma distância entre o centro em relação a cada grupo.

Nesse caso, o processo de segmentação foi adequado para separar os grãos do fundo. É comparável a outra técnica utilizada, a técnica de Otsu.

Fig 6: Processo de segmentação de sementes de feijão por meio da técnica de K-means.



Fonte: Dumbá (2020)


f) Realize a segmentação da imagem utilizando a técnica de watershed. Apresente as imagens obtidas neste processo.

A técnica de watershed é conhecida como bacia hidrográfica. Ela permite segmentar objetos que estão conectados, o que não acontece com essa imagem, uma vez que as sementes estão todas separadas umas das outras. Para essa técnica de segmentação os objetos devem estar juntos. Nessa técnica é possível transformar uma imagem bidimensional numa superfície topográfica para facilitar o tipo de segmentação. Para obter uma máscara utilizamos a função `cv2.threshold` na qual iremos obter uma limiarização para selecionar apenas os objetos de interesse separados do fundo da imagem. Nesse caso, é calculado a menor distância em relação aos pontos no fundo e é gerado uma nova matriz da mesma dimensão da máscara.

Podemos observar as distâncias por meio da imagem em JET em que os pontos mais próximos ao fundo apresentam a coloração mais clara até a vermelha e os pontos que correspondem aos grãos possuem uma coloração azul.

Como nesse exemplo nossos objetos que correspondem aos grãos de feijão não estavam conectados, isso representou um obstáculo para essa técnica. Não conseguimos fazer um processo perfeito de segmentação, uma vez que os pontos que foram preenchidos para separar os objetos na maioria dos casos contemplavam o fundo da imagem e isso fez com que a seleção do objeto de interesse que no caso é um grão de feijão viesse junto com uma área do fundo. Desse modo, essa técnica de segmentação não é adequada para objetos que não se encontram ligados como no caso das batatas que foi relatado na aula 28 (Aula 8_ex_4). Acreditamos que essa foi a questão principal para a não eficiência dessa técnica de segmentação na imagem utilizada.

Fig 7: Processo de segmentação por meio da técnica de watershed




Fonte: Dumbá (2020)

g) Compare os resultados das três formas de segmentação (limiarização, k-means e watershed) e identifique as potencialidades de cada delas.

A técnica de segmentação de OTSU utiliza um limiar automático que é determinado por meio de um histograma que separa em dois picos o objeto de interesse e também o fundo da imagem. Essa técnica é extremamente adequada para os grãos de feijão, uma vez que foi possível segmentar com alta qualidade os grãos em relação ao fundo da imagem. Outra técnica que teve uma eficiência comparável ao da técnica de limiarização foi a de K-means. Ela também foi adequada para o processo de segmentação, uma vez que garantiu a separação do fundo da imagem e dos grãos. No entanto, a técnica de segmentação de Watershed não garantiu um processo de segmentação adequado, pois o resultado final consistiu de uma semente de feijão com uma superfície de fundo da imagem.

Fig 8: Imagens de sementes de feijão oriundas de diferentes técnicas de segmentação.



Fonte: Dumbá (2020)

2. REFERÊNCIAS:

CARNEIRO, V. Q. Apostila: Visão Computacional (2020).

